Linux/Android开发记录 学习、记录、分享Linux/Android开发技术

个人资料

liuhaoyutz

访问： 80625次
积分： 1673分
排名： 第7877名

原创： 83篇 转载： 0篇
译文： 0篇 评论： 59条

LDD3源码分析之内存映射

分类： LDD3源码分析 2012-04-12 09:45 2336人阅读 评论(5) 收藏 举报

struct file tree module permissions list

作者：刘昊昱

博客：http://blog.csdn.net/liuhaoyutz

编译环境：Ubuntu 10.10

内核版本：2.6.32-38-generic-pae

LDD3源码路径：examples/simple/

本文分析LDD3第十五章介绍的内存映射模块simple。

一、simple模块编译

在2.6.32-38-generic-pae内核下编译simple模块时，会遇到一些问题，下面列出遇到的问题及解决办法。

执行make编译simple模块，会出现如下错误：

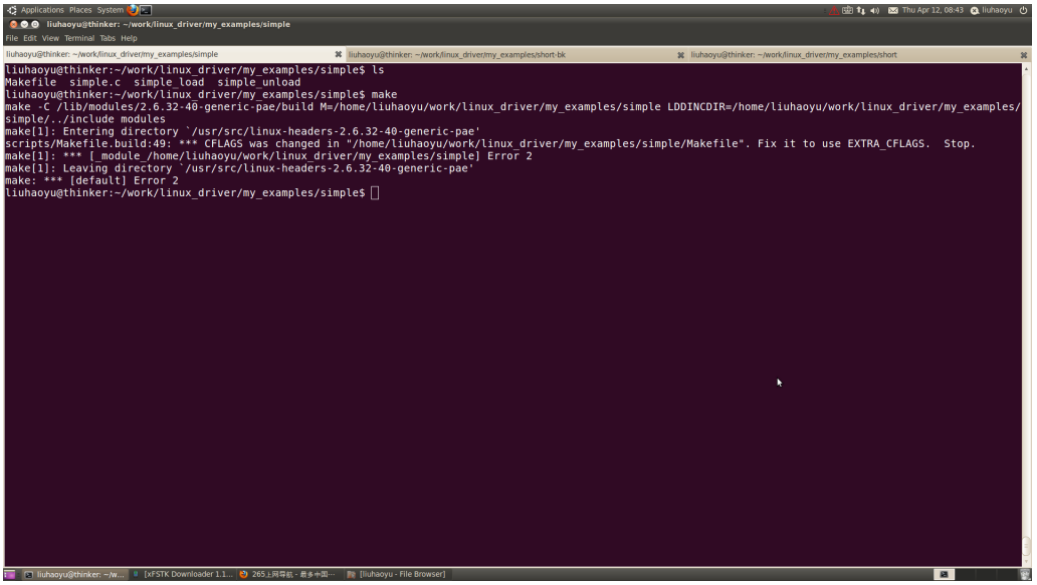

修改Makefile文件，把CFLAGS改为EXTRA_CFLAGS即可解决这个问题。再次编译，出现如下错误：

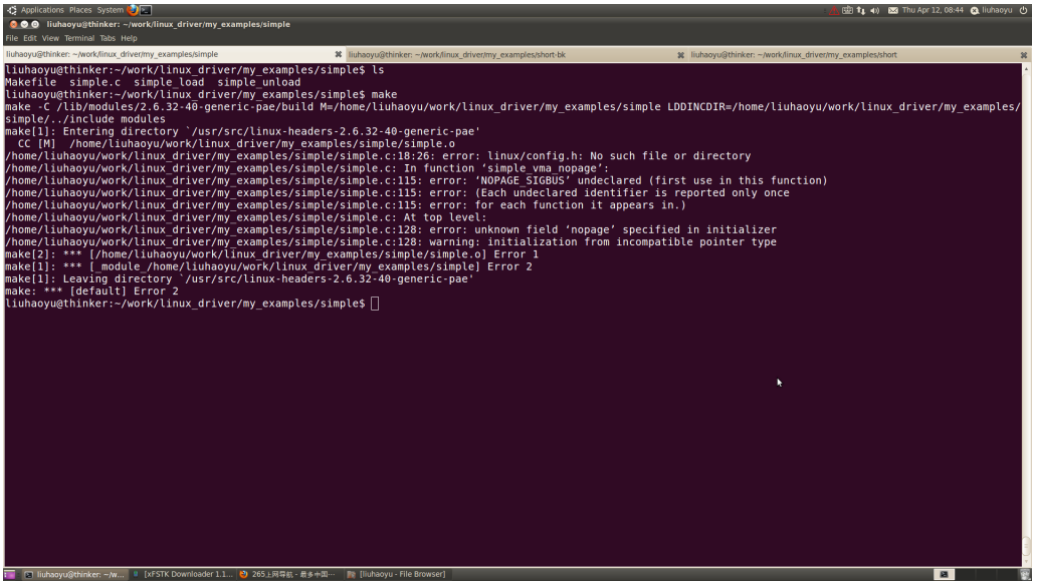

修改simple.c把第18行#include <linux/config.h>屏蔽掉，即可解决第一个错误，再次编译，出现如下错误：

simple.c的第115行，NOPAGE_SIGBUS宏在新的内核中已经不存在了，在2.6.10中该宏被定义为NULL，所以这里把115行改为

```
[cpp]
115         return 0;
```

再次编译，出现如下错误：

2014年01月 (1)
2013年12月 (6)
展开

文章搜索

推荐文章

这是因为在新的内核中vm_operations_struct结构体的nopage函数已经被fault函数代替，所以把128行改为：

```cpp
128    .fault =  simple_vma_nopage,
```

同时，按照fault的函数原型，重新改写simple_vma_nopage函数如下：

```cpp
102int simple_vma_nopage(struct vm_area_struct *vma,
103                                struct vm_fault *vmf)
104{
105    struct page *pageptr;
106    unsigned long offset = vma->vm_pgoff << PAGE_SHIFT;
107    unsigned long physaddr = (unsigned long)vmf->virtual_address - vma->vm_start + offset;
108    unsigned long pageframe = physaddr >> PAGE_SHIFT;
109
110// Eventually remove these printks
111    printk (KERN_NOTICE "---- Nopage, off %lx phys %lx\n", offset, physaddr);
112    printk (KERN_NOTICE "VA is %p\n", __va (physaddr));
113    printk (KERN_NOTICE "Page at %p\n", virt_to_page (__va (physaddr)));
114    if (!pfn_valid(pageframe))
115        return 0;
116    pageptr = pfn_to_page(pageframe);
117    printk (KERN_NOTICE "page->index = %ld mapping %p\n", pageptr->index, pageptr->mapping);
118    printk (KERN_NOTICE "Page frame %ld\n", pageframe);
119    get_page(pageptr);
120//  if (type)
121//      *type = VM_FAULT_MINOR;
122    return VM_FAULT_NOPAGE;
123}
```

再次编译，模块编译成功，如下图所示：

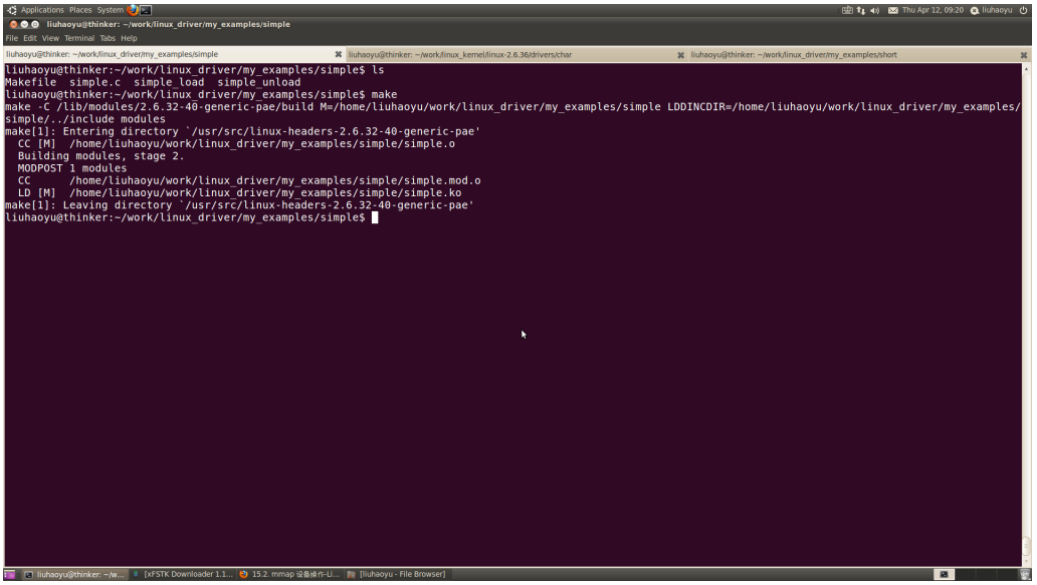

二、simple模块分析

首先来看simple模块初始化函数simple_init：

```cpp
197/*
198 * Module housekeeping.
199 */
200static int simple_init(void)
201{
202    int result;
203    dev_t dev = MKDEV(simple_major, 0);
204
205    /* Figure out our device number. */
206    if (simple_major)
207        result = register_chrdev_region(dev, 2, "simple");
208    else {
209        result = alloc_chrdev_region(&dev, 0, 2, "simple");
210        simple_major = MAJOR(dev);
211    }
212    if (result < 0) {
213        printk(KERN_WARNING "simple: unable to get major %d\n", simple_major);
214        return result;
215    }
216    if (simple_major == 0)
217        simple_major = result;
218
219    /* Now set up two cdevs. */
220    simple_setup_cdev(SimpleDevs, 0, &simple_remap_ops);
221    simple_setup_cdev(SimpleDevs + 1, 1, &simple_nopage_ops);
222    return 0;
223}
```

203 - 217行，分配设备编号。

220行，创建字符设备，文件操作函数集是simple_remap_ops，使用remap_pfn_range映射内存。

221行，创建字符设备，文件操作函数集是simple_nopage_ops，使用nopage映射内存。

simple_setup_cdev函数定义如下：

```cpp
145/*
146 * Set up the cdev structure for a device.
147 */
148static void simple_setup_cdev(struct cdev *dev, int minor,
149        struct file_operations *fops)
150{
151    int err, devno = MKDEV(simple_major, minor);
```

```
152
153    cdev_init(dev, fops);
154    dev->owner = THIS_MODULE;
155    dev->ops = fops;
156    err = cdev_add (dev, devno, 1);
157    /* Fail gracefully if need be */
158    if (err)
159        printk (KERN_NOTICE "Error %d adding simple%d", err, minor);
160}
```

simple_setup_cdev函数关联字符设备文件操作函数集，并向内核注册字符设备。

下面先来看simple_remap_ops文件操作函数集：

```
[cpp]
166/* Device 0 uses remap_pfn_range */
167static struct file_operations simple_remap_ops = {
168    .owner   = THIS_MODULE,
169    .open    = simple_open,
170    .release = simple_release,
171    .mmap    = simple_remap_mmap,
172};
```

simple_open和simple_release函数的实现都是简单返回0.

```
[cpp]
43static int simple_open (struct inode *inode, struct file *filp)
44{
45    return 0;
46}

52static int simple_release(struct inode *inode, struct file *filp)
53{
54    return 0;
55}
```

simple_remap_mmap函数的实现如下：

```
[cpp]
85static int simple_remap_mmap(struct file *filp, struct vm_area_struct *vma)
86{
87    if (remap_pfn_range(vma, vma->vm_start, vma->vm_pgoff,
88                vma->vm_end - vma->vm_start,
89                vma->vm_page_prot))
90        return -EAGAIN;
91
92    vma->vm_ops = &simple_remap_vm_ops;
93    simple_vma_open(vma);
94    return 0;
95}
```

这里我们要介绍一下，当用户空间调用mmap执行内存映射时，file_operations结构的mmap函数被调用，其函数原型是：

```
[cpp]
int (*mmap)(struct file *filp, struct vm_area_struct *vma);
```

其中vma包含了用于访问设备的虚拟地址信息。vma中vm_area_struct结构体类型，该结构体用于描述一个虚拟内存区，在2.6.10上，其定义如下：

```
[cpp]
 55/*
 56 * This struct defines a memory VMM memory area. There is one of these
 57 * per VM-area/task.  A VM area is any part of the process virtual memory
```

```
 58 * space that has a special rule for the page-fault handlers (ie a shared
 59 * library, the executable area etc).
 60 */
61struct vm_area_struct {
 62    struct mm_struct * vm_mm;   /* The address space we belong to. */
 63    unsigned long vm_start;     /* Our start address within vm_mm. */
 64    unsigned long vm_end;       /* The first byte after our end address
 65                       within vm_mm. */
 66
 67    /* linked list of VM areas per task, sorted by address */
 68    struct vm_area_struct *vm_next;
 69
 70    pgprot_t vm_page_prot;      /* Access permissions of this VMA. */
 71    unsigned long vm_flags;     /* Flags, listed below. */
 72
 73    struct rb_node vm_rb;
 74
 75    /*
 76     * For areas with an address space and backing store,
 77     * linkage into the address_space->i_mmap prio tree, or
 78     * linkage to the list of like vmas hanging off its node, or
 79     * linkage of vma in the address_space->i_mmap_nonlinear list.
 80     */
 81    union {
 82        struct {
 83            struct list_head list;
 84            void *parent;   /* aligns with prio_tree_node parent */
 85            struct vm_area_struct *head;
 86        } vm_set;
 87
 88        struct prio_tree_node prio_tree_node;
 89    } shared;
 90
 91    /*
 92     * A file's MAP_PRIVATE vma can be in both i_mmap tree and anon_vma
 93     * list, after a COW of one of the file pages.  A MAP_SHARED vma
 94     * can only be in the i_mmap tree.  An anonymous MAP_PRIVATE, stack
 95     * or brk vma (with NULL file) can only be in an anon_vma list.
 96     */
 97    struct list_head anon_vma_node; /* Serialized by anon_vma->lock */
 98    struct anon_vma *anon_vma;  /* Serialized by page_table_lock */
 99
100    /* Function pointers to deal with this struct. */
101    struct vm_operations_struct * vm_ops;
102
103    /* Information about our backing store: */
104    unsigned long vm_pgoff;     /* Offset (within vm_file) in PAGE_SIZE
105                       units, *not* PAGE_CACHE_SIZE */
106    struct file * vm_file;      /* File we map to (can be NULL). */
107    void * vm_private_data;     /* was vm_pte (shared mem) */
108
109#ifdef CONFIG_NUMA
110    struct mempolicy *vm_policy;    /* NUMA policy for the VMA */
111#endif
112};
```

vm_area_struct结构体描述的虚拟内存区介于vm_start和vm_end之间，vm_ops成员指向这个VMA的操作函数集，其类型为vm_operations_struct结构体，定义如下：

```
[cpp]

170/*
171 * These are the virtual MM functions - opening of an area, closing and
172 * unmapping it (needed to keep files on disk up-to-date etc), pointer
173 * to the functions called when a no-page or a wp-page exception occurs.
174 */
175struct vm_operations_struct {
176    void (*open)(struct vm_area_struct * area);
177    void (*close)(struct vm_area_struct * area);
178    struct page * (*nopage)
(struct vm_area_struct * area, unsigned long address, int *type);
179    int (*populate)
(struct vm_area_struct * area, unsigned long address, unsigned long len, pgprot_t prot, uns
igned long pgoff, int nonblock);
180#ifdef CONFIG_NUMA
181    int (*set_policy)(struct vm_area_struct *vma, struct mempolicy *new);
182    struct mempolicy *(*get_policy)(struct vm_area_struct *vma,
```

```
183                     unsigned long addr);
184#endif
185};
```

当用户调用mmap系统调用时,内核会进行如下处理:

1. 在进程的虚拟空间查找一块VMA.

2. 将这块VMA进行映射.

3. 如果设备驱动程序中定义了mmap函数,则调用它.

4. 将这个VMA插入到进程的VMA链表中.

内存映射工作大部分由内核完成，驱动程序中的mmap函数只需要为该地址范围建立合适的页表，并将vma->vm_ops替换为一系列的新操作就可以了。有两种建立页表的方法，一是使用remap_pfn_range函数一次全部建立，或者通过nopage方法每次建立一个页表。

simple_remap_mmap函数使用remap_pfn_range函数一次建立全部页表，remap_pfn_range函数原型如下：

```
[cpp]
int remap_pfn_range(struct vm_area_struct *vma, unsigned long virt_addr, unsigned long pfn,
 unsigned long size, pgprot_t prot);
```

vma代表虚拟内存区域。

virt_addr代表要建立页表的用户虚拟地址的起始地址，remap_pfn_range函数为处于virt_addr和virt_addr+size之间的虚拟地址建立页表。

pfn是与物理内存起始地址对应的页帧号，虚拟内存将要被映射到该物理内存上。页帧号只是将物理地址右移PAGE_SHIFT位。在大多数情况下，VMA结构中的vm_pgoff赋值给pfn即可。remap_pfn_range函数建立页表，对应的物理地址是pfn<<PAGE_SHIFT到pfn<<(PAGE_SHIFT)+size。

size代表虚拟内存区域大小。

port是VMA要求的protection属性，驱动程序只要使用vma->vm_page_prot中的值即可。

在simple_remap_mmap函数中，

87 - 90行，调用remap_pfn_range函数建立页表：

```
[cpp]
remap_pfn_range(vma, vma->vm_start, vma->vm_pgoff,
                vma->vm_end - vma->vm_start,
                vma->vm_page_prot)
```

可对比上面对remap_pfn_range函数的参数的解释来理解。

92行，vma->vm_ops是struct vm_operations_struct类型变量，代表内核操作虚拟内存区的函数集，这里赋值为simple_remap_vm_ops，其定义如下：

```
[cpp]
80static struct vm_operations_struct simple_remap_vm_ops = {
81    .open =  simple_vma_open,
82    .close = simple_vma_close,
83};
```

这里仅仅实现了open和close函数，其它函数由内核提供。当进程打开或关闭VMA时，就会调用这两个函数，当fork进程或者创建一个新的对VMA引用时，也会调用open函数。实际的打开和关闭工作由内核完成，这里实现的open和close函数不必重复内核所做的工作，只要根据驱动程序的需要处理其他必要的事情。对于simple这样的简单驱动程

序，simple_vma_open和simple_vma_close函数仅仅是打印相关信息：

```cpp
63void simple_vma_open(struct vm_area_struct *vma)
64{
65    printk(KERN_NOTICE "Simple VMA open, virt %lx, phys %lx\n",
66            vma->vm_start, vma->vm_pgoff << PAGE_SHIFT);
67}
68
69void simple_vma_close(struct vm_area_struct *vma)
70{
71    printk(KERN_NOTICE "Simple VMA close.\n");
72}
```

回到simple_remap_mmap函数：

93行，显式调用simple_vma_open(vma)，这里要注意，必须显示调用该函数，因为open函数还没有注册到系统。

至此，Device 0的相关代码就分析完了。

除了remap_pfn_range函数外，在驱动程序中实现nopage函数通常可以为设备提供更加灵活的内存映射途径。当访问的页面不在内存，即发生缺页中断时，nopage就会被调用。这是因为，当发生缺页中断时，系统会经过如下处理过程：

1. 找到缺页的虚拟地址所在的VMA。

2. 如果必要，分配中间页目录表和页表。

3. 如果页表项对应的物理页面不存在，则调用nopage函数，它返回物理页面的页描述符。

4. 将物理页面的地址填充到页表中。

下面我们看Device 1的相关代码，其文件操作函数集如下：

```cpp
174/* Device 1 uses nopage */
175static struct file_operations simple_nopage_ops = {
176    .owner   = THIS_MODULE,
177    .open    = simple_open,
178    .release = simple_release,
179    .mmap    = simple_nopage_mmap,
180};
```

与Device 0相比，只有mmap的实现不一样，我们看simple_nopage_mmap：

```cpp
131static int simple_nopage_mmap(struct file *filp, struct vm_area_struct *vma)
132{
133    unsigned long offset = vma->vm_pgoff << PAGE_SHIFT;
134
135    if (offset >= __pa(high_memory) || (filp->f_flags & O_SYNC))
136        vma->vm_flags |= VM_IO;
137    vma->vm_flags |= VM_RESERVED;
138
139    vma->vm_ops = &simple_nopage_vm_ops;
140    simple_vma_open(vma);
141    return 0;
142}
```

135 - 137行，设置vma->vm_flags标志。

139行，指定vma->vm_ops为simple_nopage_vm_ops。

140行，显式调用simple_vma_open函数。

simple_nopage_vm_ops结构定义如下：

```cpp
125static struct vm_operations_struct simple_nopage_vm_ops = {
126    .open =   simple_vma_open,
127    .close =  simple_vma_close,
128    .nopage = simple_vma_nopage,
129};
```

这个结构体中，需要分析的是simple_vma_nopage函数：

```cpp
102struct page *simple_vma_nopage(struct vm_area_struct *vma,
103                unsigned long address, int *type)
104{
105    struct page *pageptr;
106    unsigned long offset = vma->vm_pgoff << PAGE_SHIFT;
107    unsigned long physaddr = address - vma->vm_start + offset;
108    unsigned long pageframe = physaddr >> PAGE_SHIFT;
109
110// Eventually remove these printks
111    printk (KERN_NOTICE "---- Nopage, off %lx phys %lx\n", offset, physaddr);
112    printk (KERN_NOTICE "VA is %p\n", __va (physaddr));
113    printk (KERN_NOTICE "Page at %p\n", virt_to_page (__va (physaddr)));
114    if (!pfn_valid(pageframe))
115        return NOPAGE_SIGBUS;
116    pageptr = pfn_to_page(pageframe);
117    printk (KERN_NOTICE "page->index = %ld mapping %p\n", pageptr->index, pageptr->mapping);
118    printk (KERN_NOTICE "Page frame %ld\n", pageframe);
119    get_page(pageptr);
120    if (type)
121        *type = VM_FAULT_MINOR;
122    return pageptr;
123}
```

106行，得到起始物理地址保存在offset中。

107行，得到address参数对应的物理地址，保存在physaddr中。

108行，得到address的物理地址对应的页帧号，保存在pageframe中。

116行，使用pfn_to_page函数，由页帧号返回对应的page结构指针保存在pageptr中。

119行，调用get_page增加pageptr指向页面的引用计数。

至此，simple模块的代码我们就分析完了。

更多 0

上一篇 LDD3源码分析之与硬件通信&中断处理

下一篇 S3C2410驱动分析之ADC通用驱动

linux内核DMA内存分配
交叉编译环境下静态库动态库的加载
linux input输入子系统分析《二》：s3c2440的ADC简单
u-boot编译笔记

查看评论

4楼 frogcoder 2013-06-05 15:28发表

107行的physaddr表示的是调整以后的物理地址？

Re: wzw88486969 2014-06-03 08:45发表

回复fjlhlonng：unsigned long offset = vma->vm_pgoff << PAGE_SHIFT;
unsigned long physaddr = address - vma->vm_start + offset;
vma->vm_pgoff //页帧号
offset//页的开始地址
address - vma->vm_start //用户虚拟地址-用户虚拟开始地址=
在这一页里面的偏移
offset+address - vma->vm_start//，得到address参数对应的物理地址

不知道我说的对不对，
那个offset的命名，有点让人。。。。。

3楼 frogcoder 2013-06-05 15:16发表

LZ,我对int simple_vma_nopage这个函数的107行不是很理解，106行的计算不是已经是物理地址了嘛？可以解释一下么？

2楼 angelbosj 2012-07-06 17:42发表

对照了LDD3，今天看完了你所有的博客。你真的很强。 佩服， 佩服。

1楼 wjzwjs 2012-06-02 03:55发表

哥们儿，辛苦了。解释地很细，受益匪浅。